Sample Document for PDF Chunking & OCR Testing

Section 1: Introduction

This document is designed to test PDF text extraction, chunking, and optical character recognition (OCR) pipelines. It contains multiple content types including structured paragraphs, tables, and embedded images with printed text.

Section 2: Key Concepts

• **PDF Chunking:** Splitting a document into semantically meaningful segments for retrieval or processing.

• **OCR Extraction:** Recognizing text embedded within raster images inside a PDF.

• **Layout Analysis:** Identifying headings, paragraphs, tables, and figures for structured output.

• **Embedding:** Converting text chunks into vector representations for similarity search.

Section 3: Sample Data Table

ID	Name	Category	Score
001	Alpha Module	Extraction	92%
002	Beta Module	Chunking	88%
003	Gamma Module	OCR	95%
004	Delta Module	Embedding	90%

Section 4: Embedded Image with Text (OCR Target)

The image below contains printed text. An OCR engine should be able to extract the invoice fields from it.


```
1:  ▾ [18 +
    0:  ▸ {6 + }  ,
    1:  ▸ {6 + }  ,
    2:  ▸ {6 + }  ,
    3:  ▸ {6 + }  ,
    4:  ▸ {6 + }  ,
    5:  ▸ {6 + }  ,
    6:  ▸ {6 + }  ,
    7:  ▸ {6 + }  ,
    8:  ▸ {6 + }  ,
    9:  ▸ {6 + }  ,
    10:  ▸ {6 + }  ,
    11:  ▸ {6 + }  ,
    12:  ▸ {6 + }  ,
    13:  ▸ {6 + }  ,
    14:  ▸ {6 + }  ,
    15:  ▸ {6 + }  ,
    16:  ▸ {6 + }  ,
    17:  ▸ {6 + }
```


Section 5: Extended Body Text

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Vestibulum tortor quam, feugiat vitae, ultricies eget, tempor sit amet, ante. Donec eu libero sit amet quam egestas semper. Aenean ultricies mi vitae est. Mauris placerat eleifend leo.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Vestibulum tortor quam, feugiat vitae, ultricies eget, tempor sit amet, ante. Donec eu libero sit amet quam egestas semper. Aenean ultricies mi vitae est. Mauris placerat eleifend leo.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Vestibulum tortor quam, feugiat vitae, ultricies eget, tempor sit amet, ante. Donec eu libero sit amet quam egestas semper. Aenean ultricies mi vitae est. Mauris placerat eleifend leo.

Section 6: Conclusion

This test document covers plain text paragraphs, a structured table, and an embedded raster image containing printed text. Together these exercise the major challenges faced by document intelligence pipelines.